

# Análisis de Factores

Cristian Guarnizo-Lemus  
cristianguarnizo@itm.edu.co

Maestria en Automatización y Control Industrial

# Contenido

- 1 Introducción
- 2 Modelo de Factores Ortogonales
  - Calculo de matriz de pesos
- 3 Seleccionando el numero de factores
- 4 Validación del Análisis de Factores

# Contenido

## 1 Introducción

## 2 Modelo de Factores Ortogonales

- Cálculo de matriz de pesos

## 3 Seleccionando el número de factores

## 4 Validación del Análisis de Factores

## Introducción

- En FA representamos las variables  $x_1, x_2, \dots, x_p$  como una combinación lineal de unas pocas variables  $z_1, z_2, \dots, z_m$  ( $m < p$ ) llamados factores.
- Los factores son variables latentes que generan los  $x$ 's.
- Si las variables originales  $x_1, x_2, \dots, x_p$  están moderadamente correlacionadas, la dimensionalidad básica del sistema es menor que  $p$ .
- El objetivo del análisis de factores es reducir la redundancia entre las variables usando un número pequeño de factores.

## Introducción

Ejemplo matriz de correlación

$$R = \begin{bmatrix} 1.00 & .90 & .05 & .05 & .05 \\ .90 & 1.00 & .05 & .05 & .05 \\ .05 & .05 & 1.00 & .90 & .90 \\ .05 & .05 & .90 & 1.00 & .90 \\ .05 & .05 & .90 & .90 & 1.00 \end{bmatrix}$$

## Diferencias con PCA

A pesar que PCA es también una técnica de reducción de dimensionalidad, existen 2 diferencias con FA

- Las componentes principales están definidas como una combinación lineal de la variables originales. En FA, las variables originales son expresadas como una combinación lineal de factores.
- En PCA, se explica un gran parte de la varianza total de la variables. En FA, buscamos cuantificar las covarianzas o correlaciones entre las variables.

## Diferencias con PCA

A pesar que PCA es también una técnica de reducción de dimensionalidad, existen 2 diferencias con FA

- Las componentes principales están definidas como una combinación lineal de la variables originales. En FA, las variables originales son expresadas como una combinación lineal de factores.
- En PCA, se explica un gran parte de la varianza total de la variables. En FA, buscamos cuantificar las covarianzas o correlaciones entre las variables.

# Contenido

## 1 Introducción

## 2 Modelo de Factores Ortogonales

### ■ Calculo de matriz de pesos

## 3 Seleccionando el numero de factores

## 4 Validación del Análisis de Factores



## Factores Ortogonales

Asumimos una muestra aleatoria  $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N$  con media  $\boldsymbol{\mu}$  y matriz de covarianza  $\boldsymbol{\Sigma}$ .  
Expresamos cada variable como una combinación lineal de factores comunes  $z_1, z_2, \dots, z_m$ , acompañadas con un termino de error para la parte de las variables que es única.

$$x_1 - \mu_1 = w_{11}z_1 + w_{12}z_2 + \dots + w_{1m}z_m + \epsilon_1$$

$$x_2 - \mu_2 = w_{21}z_1 + w_{22}z_2 + \dots + w_{2m}z_m + \epsilon_2$$

$$\vdots$$

$$x_p - \mu_p = w_{p1}z_1 + w_{p2}z_2 + \dots + w_{pm}z_m + \epsilon_p$$

$$\mathbf{x} - \boldsymbol{\mu} = \mathbf{W}\mathbf{z} + \boldsymbol{\epsilon}$$

## Factores Ortogonales

$$\mathbf{x} - \boldsymbol{\mu} = \mathbf{W}\mathbf{z} + \boldsymbol{\epsilon}$$

Adicionalmente, asumimos

$$\mathbb{E}[\mathbf{z}] = \mathbf{0}, \text{ cov}(\mathbf{z}) = \mathbf{I}, \mathbb{E}[\boldsymbol{\epsilon}] = \mathbf{0},$$

y

$$\text{cov}(\boldsymbol{\epsilon}) = \boldsymbol{\Psi} = \begin{bmatrix} \psi_1 & 0 & \cdots & 0 \\ 0 & \psi_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \psi_p \end{bmatrix}$$

y  $\text{cov}(\mathbf{z}, \boldsymbol{\epsilon}) = \mathbf{0}$ . Prácticamente

$$\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \boldsymbol{\Psi}), \mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}).$$

## Factores Ortogonales

Recordando que

$$\mathbf{x} = \mathbf{W}\mathbf{z} + \boldsymbol{\mu} + \boldsymbol{\epsilon}, \text{ y } \boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \boldsymbol{\Psi}), \mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}).$$

Calculamos el modelo probabilístico de  $\mathbf{x}$  así

$$\mathbb{E}[\mathbf{x}] = \mathbb{E}[\mathbf{W}\mathbf{z}] + \mathbb{E}[\boldsymbol{\mu}] + \mathbb{E}[\boldsymbol{\epsilon}],$$

$$\begin{aligned} \text{cov}(\mathbf{x}) &= \mathbb{E}[(\mathbf{x} - \boldsymbol{\mu})(\mathbf{x} - \boldsymbol{\mu})^\top] \\ &= \mathbb{E}[(\mathbf{W}\mathbf{z} + \boldsymbol{\epsilon})(\mathbf{W}\mathbf{z} + \boldsymbol{\epsilon})^\top] \\ &= \mathbb{E}[\mathbf{W}\mathbf{z}\mathbf{z}^\top \mathbf{W}^\top] + \mathbb{E}[\boldsymbol{\epsilon}\boldsymbol{\epsilon}^\top] \\ &= \mathbf{W}\mathbb{E}[\mathbf{z}\mathbf{z}^\top] \mathbf{W}^\top + \mathbb{E}[\boldsymbol{\epsilon}\boldsymbol{\epsilon}^\top] \\ &= \mathbf{W}\mathbf{W}^\top + \boldsymbol{\Psi} \end{aligned}$$

$$\boldsymbol{\Sigma} = \mathbf{W}\mathbf{W}^\top + \boldsymbol{\Psi}$$

Entonces  $\mathbf{x} \sim \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ .

## Análisis de términos

$$\mathbf{x} \sim \mathcal{N}(\boldsymbol{\mu}, \mathbf{W}\mathbf{W}^{\top} + \boldsymbol{\Psi}), \mathbf{y} \sim \mathcal{N}(\mathbf{0}, \boldsymbol{\Psi}), \mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}).$$

$$\text{cov}(X_i, X_i) = \mathbf{w}_i \mathbf{w}_i^{\top} + \psi_i = \sum_{k=1}^m w_{ik}^2 + \psi_i$$

$$\text{cov}(X_i, X_j) = \mathbf{w}_i \mathbf{w}_j^{\top} = \sum_{k=1}^m w_{ik} w_{jk}$$

# Contenido

## 1 Introducción

## 2 Modelo de Factores Ortogonales

### ■ Cálculo de matriz de pesos

## 3 Seleccionando el número de factores

## 4 Validación del Análisis de Factores

## Calculo de matriz de pesos- EM

No se puede determinar  $\mathbf{W}$  de manera cerrada usando máxima verosimilitud. Pero la podemos calcular de manera iterativa empleando el algoritmo EM, del cual obtenemos los siguientes paso

■ Paso E:

$$\mathbb{E}[\mathbf{z}_n] = \mathbf{G} \mathbf{W}^\top \boldsymbol{\Psi}^{-1} (\mathbf{x}_n - \boldsymbol{\mu})$$

$$\mathbb{E}[\mathbf{z}_n \mathbf{z}_n^\top] = \mathbf{G} + \mathbb{E}[\mathbf{z}_n] \mathbb{E}[\mathbf{z}_n]^\top$$

con  $\mathbf{G} = (\mathbf{I} + \mathbf{W}^\top \boldsymbol{\Psi}^{-1} \mathbf{W})^{-1}$ .

■ Paso M:

$$\mathbf{W}^{\text{new}} = \left[ \sum_{n=1}^N (\mathbf{x}_n - \boldsymbol{\mu}) \mathbb{E}[\mathbf{z}_n]^\top \right] \left[ \sum_{n=1}^N \mathbb{E}[\mathbf{z}_n \mathbf{z}_n^\top] \right]^{-1}$$

$$\boldsymbol{\Psi}^{\text{new}} = \text{diag} \left\{ \mathbf{S} - \mathbf{W}^{\text{new}} \frac{1}{N} \sum_{n=1}^N \mathbb{E}[\mathbf{z}_n] (\mathbf{x}_n - \boldsymbol{\mu})^\top \right\}$$

## Calculo de matriz de pesos- PC

- De la muestra aleatoria  $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$  se obtiene la matriz de covarianza muestral  $\mathbf{S}$  e intentamos encontrar un estimador de  $\hat{\mathbf{W}}$  que aproxime

$$\mathbf{S} \approx \hat{\mathbf{W}}\hat{\mathbf{W}}^T + \hat{\boldsymbol{\Psi}}.$$

- En este método, olvidamos  $\hat{\boldsymbol{\Psi}}$ , entonces  $\mathbf{S} = \hat{\mathbf{W}}\hat{\mathbf{W}}^T$ . Para factorizar  $\mathbf{S}$  empleamos SVD

$$\mathbf{S} = \mathbf{U}\mathbf{D}\mathbf{U}^T,$$

donde  $\mathbf{U}$  es una matriz ortogonal construida con los vectores propios normalizados y  $\mathbf{D}$  es una matriz diagonal con valores propios  $\lambda_1, \lambda_2, \dots, \lambda_p$  de  $\mathbf{S}$ .

- Se aproxima la matriz  $\hat{\mathbf{W}} = \mathbf{U}\mathbf{D}^{1/2}$ .

## Calculo de matriz de pesos- PC

$$\begin{bmatrix} \hat{W}_{11} & \hat{W}_{12} \\ \hat{W}_{21} & \hat{W}_{22} \\ \hat{W}_{31} & \hat{W}_{32} \\ \hat{W}_{41} & \hat{W}_{42} \\ \hat{W}_{51} & \hat{W}_{52} \end{bmatrix} = \begin{bmatrix} U_{11} & U_{12} \\ U_{21} & U_{22} \\ U_{31} & U_{32} \\ U_{41} & U_{42} \\ U_{51} & U_{52} \end{bmatrix} \begin{bmatrix} \sqrt{\lambda_1} & 0 \\ 0 & \sqrt{\lambda_2} \end{bmatrix} == \begin{bmatrix} \sqrt{\lambda_1} U_{11} & \sqrt{\lambda_2} U_{12} \\ \sqrt{\lambda_1} U_{21} & \sqrt{\lambda_2} U_{22} \\ \sqrt{\lambda_1} U_{31} & \sqrt{\lambda_2} U_{32} \\ \sqrt{\lambda_1} U_{41} & \sqrt{\lambda_2} U_{42} \\ \sqrt{\lambda_1} U_{51} & \sqrt{\lambda_2} U_{52} \end{bmatrix}$$



## Calculo de matriz de pesos- PC PF - Ejemplo

Variables	Principal Component Loadings		Principal Factor Loadings		Communalities
	$Z_1$	$Z_2$	$Z_1$	$Z_2$	
Kind	.969	-.231	.981	-.210	.995
Intelligent	.519	.807	.487	.774	.837
Happy	.785	-.587	.771	-.544	.881
Likeable	.971	-.210	.982	-.188	.995
Just	.704	.667	.667	.648	.837
Variance accounted for	3.263	1.538	3.202	1.395	
Proportion of total variance	.653	.308	.704	.307	
Cumulative proportion	.653	.960	.704	1.01	

# Contenido

- 1 Introducción
- 2 Modelo de Factores Ortogonales
  - Calculo de matriz de pesos
- 3 Seleccionando el numero de factores
- 4 Validación del Análisis de Factores

## Seleccionando el numero de factores

- Seleccione  $m$  igual al numero de factores necesarios para describir una varianza predeterminada (80%) del total de la varianza  $\text{tr}(\mathbf{S})$ .
- Seleccione  $m$  igual al numero de valores propios mayor que su promedio.
- Usa el test scree o “scree plot” (L curva) basado en el gráfico de los valores propios de  $\mathbf{S}$  o  $\mathbf{R}$ . Si la gráfica baja abruptamente, seguida de una linea recta con una pendiente pequeña, seleccione  $m$  igual al numero de valores propios antes de comenzar la linea recta.
- Pruebe la hipótesis que  $m$  es el numero correcto de factores (sobre EM),  
 $H_0 : \Sigma = \mathbf{W}\mathbf{W}^T + \Psi$ .

$$\left( n - \frac{2p + 4m + 11}{6} \right) \ln \left( \frac{|\hat{\mathbf{W}}\hat{\mathbf{W}}^T + \hat{\Psi}|}{|\mathbf{S}|} \right) \sim \chi^2_v, \quad v = \frac{1}{2}[(p - m)^2 - p - m].$$

# Contenido

- 1 Introducción
- 2 Modelo de Factores Ortogonales
  - Calculo de matriz de pesos
- 3 Seleccionando el numero de factores
- 4 Validación del Análisis de Factores

## Validación del Análisis de Factores

- Para muchos estadistas, FA es controversial y no pertenece a una técnica multivariada legítima.
- Las razones son: la dificultad para seleccionar  $m$ , la variedad de métodos para extraer los factores, muchas técnicas rotaciones, y la subjetividad en interpretación.

## Referencias

- Alvin C. Rencher. “Methods of Multivariate Analysis”, 2002. Capítulo 13.
- C. Bishop. “Pattern Recognition and Machine Learning”, 2006. Sección 12.2.4.
- W. K. Härdle and L. Simar. “Applied Multivariate Statistical Analysis”, 2019. Capítulo 12.